

MIT em Engenharia de Dados: BigData Trabalho Da Disciplina Infraestrutura Hadoop

Aluno: Charles de Araujo Melo

## 1. Introdução

Hadoop destaca-se como uma tecnologia aberta, baseada no paradigma MapReduce, que utiliza a computação paralela e distribuída para resolver o problema da escalabilidade no processamento de BigData, com garantias de tolerância a falhas. Das vantagens em adotá-lo, está o fato de se utilizar aglomerados de máquinas convencionais, tornando-o eficaz como solução de baixo custo de implantação. Ademais, com ele as empresas podem conquistar uma grande vantagem competitiva, dispondo de um mecanismo que possibilita avaliar grandes quantidades de dados em busca de novas informações.

Através dos procedimentos das praticas laboratoriais se utilizando como ferramenta de trabalho um dos serviços da nuvem da google, google cloud, serão discutidos e elaborados um estudo prático utilizando a ferramenta Hive para responder um conjunto de perguntas elaboradas na prática laboratorial. As Bases de dados utilizadas no trabalho são: demogra\_cliente, end\_cliente e transacoes.

## 2. Objetivos

Objetivo é por em prática no dia a dia, planejando e implementando projetos que envolvam a infraestrutura Hadoop e como utilizá-la na solução de problemas que envolvam grande quantidades de dados.

## 3. Descrição

Minha base de dados é de uma loja de venda de bicicletas onde utilizarei para identificar vantagens empresariais para futuro aumento de vendas e conhecer melhor as características dos clientes para maiores captações.

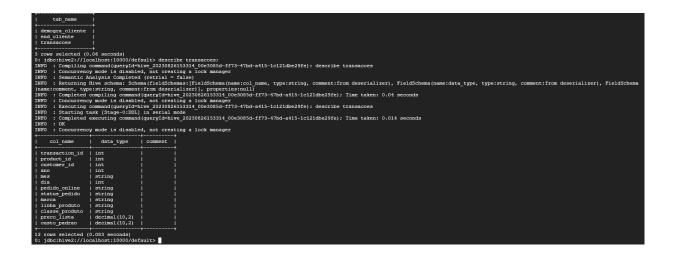
1. Visão geral do esquema de dados (caracterização das tabelas, dicionário de dados, etc.)

# describe demogra\_cliente;

# describe end\_cliente;

```
tab_name |
| demogra_rliente |
| demogra_rliente |
| demogra_rliente |
| trainscors |
| trainsco
```

### describe transacoes;



- **2.** Identificação das fontes de onde os dados foram obtidos <a href="https://www.kaggle.com/datasets/rohitsahoo/bicycle-store-dataset">https://www.kaggle.com/datasets/rohitsahoo/bicycle-store-dataset</a>
- 3. Construção de um *database* no Hive que implemente o esquema proposto

#### Conectando no Hive

create database charles\_hadoop;

beeline -u jdbc:hive2://localhost:10000/default -n charlesmeloti@cluster-charlesmeloti@c

```
Linux cluster-charles-m 5.10.0-25-cloud-amd64 $1 SMP Debian 5.10.191-1 (2023-08-16) x86_64

The programs included with the Debian GNU/Linux system are free software;
the exact distribution terms for each program are described in the
individual files in /usr/share/doc/*/copyright.

Debian GNU/Linux comes with ABSOLUTELY NO WARRATHY, to the extent
permitted by applicable law.

Last login: Sat Aug 26 15:27:56 2023 from 35.235.241.18
charlesselotieGluster-charles-m:-$ beeline -u jduc:hive2://localhost:10000/default -n charlesmeloti@cluster-charles-m -d org.apache.hive.jdbc.HiveDriver
Connecting to jduc:hive2://localhost:10000/default

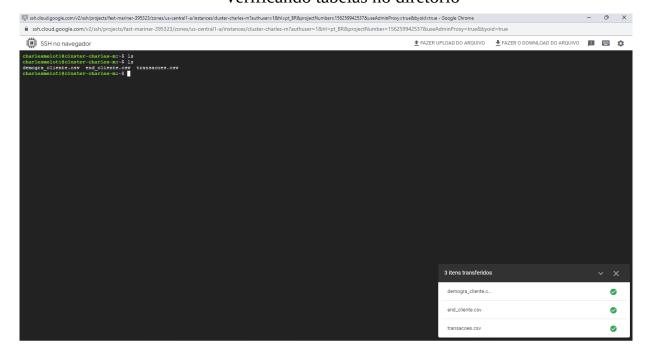
Connected to: Apache Hive (version 3.1.3)

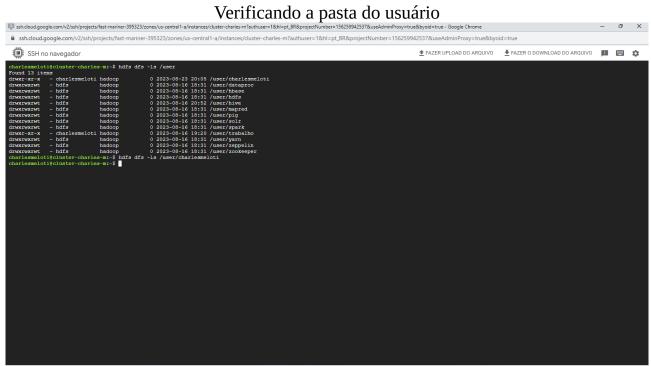
Driver: Hive UDBC (version 3.1.3)

Transaction isolation: TRANSACTION REPEATABLE_READ
Beeline version 3.1.3 by Apache Hive

0: jdbc:hive2://localhost:10000/default>
```

#### Verificando tabelas no diretório



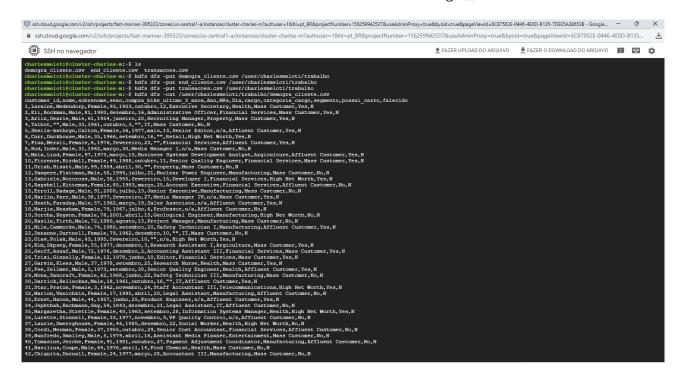


#### Enviando os arquivos para a partição

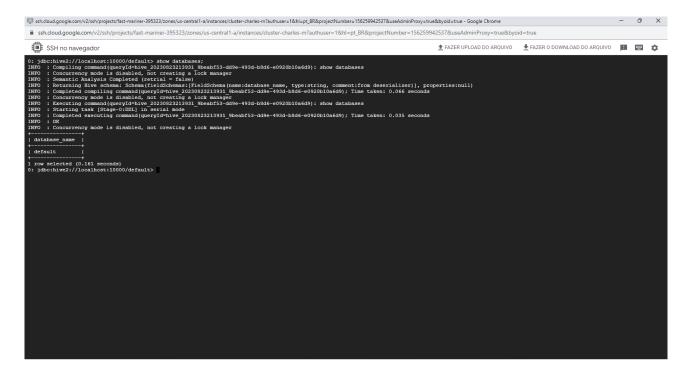
```
demogra_cliente.csv end_cliente.csv transacoes.csv
charlesmeloti@cluster-charles-m:~$ hdfs dfs -put end_cliente.csv /user/charlesmeloti/trabalho
charlesmeloti@cluster-charles-m:~$ hdfs dfs -put end_demogra.csv /user/charlesmeloti/trabalho
put: 'end demogra.csv': No such file or directory
charlesmeloti@cluster-charles-m:~$ hdfs dfs -put demogra_cliente.csv /user/charlesmeloti/trabalho charlesmeloti@cluster-charles-m:~$ hdfs dfs -put transacoes.csv /user/charlesmeloti/trabalho charlesmeloti@cluster-charles-m:~$
```

hdfs dfs -put end\_cliente.csv /user/charlesmeloti/trabalho hdfs dfs -put demogra\_cliente.csv /user/charlesmeloti/trabalho hdfs dfs -put transacoes.csv /user/charlesmeloti/trabalho

#### hdfs dfs -cat /user/charlesmeloti/trabalho/demogra\_cliente.csv



#### Verificando se tem database criado



#### Criando database

#### Criando tabela end\_cliente e usando describre

```
CREATE EXTERNAL TABLE end_cliente (customer_id int, endereco STRING, estado String, pais STRING, codigo_postal int)

ROW FORMAT DELIMITED

FIELDS TERMINATED BY ','

STORED AS TEXTFILE;

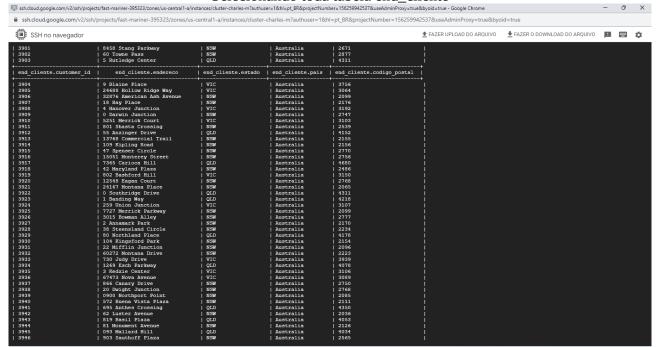
LOCATION '/user/charlesmeloti/trabalho';
```

#### describe end cliente;

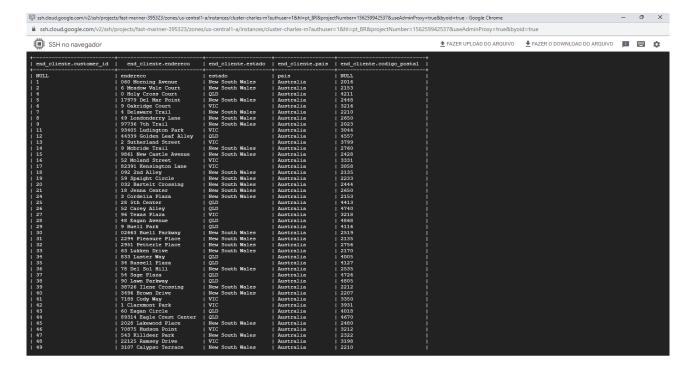
```
INTO: Computing command(query/driving 2033082501372) h17feh2-Sb19-4ce0-bla7-48a5fa38ae7): describe end_cliente
INTO: Sementic Analysis Completed (petrial = false) to manager
INTO: Sementic Analysis Completed (petrial = false) to manager
INTO: Sementic Analysis Completed (petrial = false) to manager
INTO: Computerency mode is disabled, not creating a lock manager
INTO: Concurrency mode is disabled, not creating a lock manager
INTO: Starting thas (Stage-c-DuDL) in serial mode
INTO: Starting thask (Stage-c-DuDL) in serial mode
INTO: Starting thask (Stage-c-DuDL) in serial mode
INTO: Concurrency mode is disabled, not creating a lock manager
INTO: Concurrency mode is disabled, not creating a lock manager
INTO: Concurrency mode is disabled, not creating a lock manager
INTO: Concurrency mode is disabled, not creating a lock manager
INTO: Concurrency mode is disabled, not creating a lock manager

| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Concurrency mode is disabled, not creating a lock manager
| Co
```

### Selecionando toda tabela end\_cliente



### select \* from end\_cliente limit 50;



#### Criando a tabela demogra\_cliente pelo Beeline

CREATE TABLE demogra\_cliente (customer\_id int, nome STRING, sobrenome String, sexo STRING, compra\_bike\_ultimo\_3\_ano int,

Ano int, Mes String, Dia int, cargo String, categoria\_cargo String, segmento String, possui\_carro String, falecido String

ROW FORMAT DELIMITED FIELDS TERMINATED BY ',' STORED AS TEXTFILE;

Jogando os dados na tabela demogra\_cliente

LOAD DATA INPATH '/user/charlesmeloti/trabalho/demogra\_cliente.csv' overwrite into table demogra\_cliente;

```
INFO : Compiling command(queryId=hive_20230825181527_f9844212-373a-41ea-a5d3-dd0fc89c9459): CREATE TABLE demogra_cliente (customer_id int, nome STRING, sobrenome String, sexo STRING, compra_bike_ulti mo_3 ano int,
ano int, Mes String, Dia int, cargo String, categoria_cargo String, segmento String, possui_carro String, falecido String
}

NEW FORMAT DELIMITED
FIELDS TERMINATED BY ','
STOREAD AS TEXTFILE.
INFO : Concurrency mode is disabled, not creating a lock manager
INFO : Securing Provided is disabled, not creating a lock manager
INFO : Returning Hive schema: Schema([ti-idSchemas:null) properties:null)
INFO : Returning Hive schema: Schema([ti-idSchemas:null) properties:null)
INFO : Returning Hive schema: Schema([ti-idSchemas:null) properties:null)
INFO : Executing command(queryId=hive_20230825181527_f9844212-373a-41ea-a5d3-dd0fc89c9459): Time taken: 0.782 seconds
INFO : Executing command(queryId=hive_20230825181527_f9844212-373a-41ea-a5d3-dd0fc89c9459): Time taken: 0.782 seconds
INFO : Executing command(queryId=hive_20230825181527_f9844212-373a-41ea-a5d3-dd0fc89c9459): Time taken: 0.782 seconds
INFO : Schemat DelimiteD
FIELDS TERMINATED BY ','
STOREAD AS TEXTFILE
INFO : Schemat DelimiteD
INFO : Completed executing command(queryId=hive_20230825181527_f9844212-373a-41ea-a5d3-dd0fc89c9459): Time taken: 2.67 seconds
INFO : Completed executing command(queryId=hive_20230825181527_f9844212-373a-41ea-a5d3-dd0fc89c9459): Time taken: 2.67 seconds
INFO : Completed executing command(queryId=hive_20230825181527_f9844212-373a-41ea-a5d3-dd0fc89c9459): Time taken: 2.67 seconds
INFO : Completed executing command(queryId=hive_20230825181527_f9844212-373a-41ea-a5d3-dd0fc89c9459): Time taken: 2.67 seconds
INFO : Completed executing command(queryId=hive_20230825181527_f9844212-373a-41ea-a5d3-dd0fc89c9459): Time taken: 2.67 seconds
INFO : Completed executing command(queryId=hive_20230825181527_f9844212-373a-41ea-a5d3-dd0fc89c9459): Time taken: 2.67 seconds
INFO : Completed executing command(queryId=hive_20230825181527_f9844212-373a
```

### describe demogra\_cliente;

Select \* from demogra\_cliente limit 100

| stock | sto

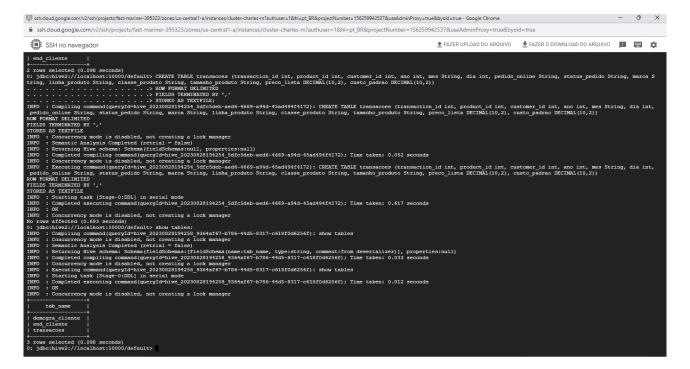
#### Criando a tabela transacoes

CREATE TABLE transacoes (transaction\_id int, product\_id int, customer\_id int, ano int, mes String, dia int, pedido\_online String, status\_pedido String, marca String, linha\_produto String, classe\_produto String, tamanho\_produto String, preco\_lista DECIMAL(10,2), custo\_padrao DECIMAL(10,2))

ROW FORMAT DELIMITED FIELDS TERMINATED BY ',' STORED AS TEXTFILE

Jogando os dados na tabela transacoes\_cliente

LOAD DATA INPATH '/user/charlesmeloti/trabalho/transacoes.csv' overwrite into table transacoes;



#### describe transacoes;

```
NRO : Concurrency mode is disabled, not creating a lock manager

No rows affected (0.51 seconds)

9. jdbc:hive2;//localhost:10000/default> describe transacces;

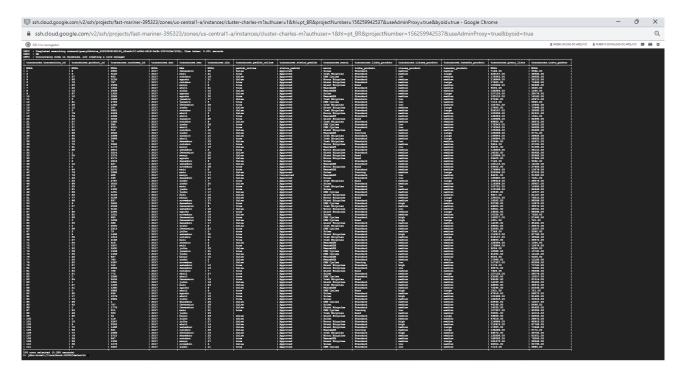
NRO : Compliang command(queryfdshive_20030028194556 986499a5-f623-fe43-9aeb-9e7276a8be6c): describe transacces

NRO : Compliang command(queryfdshive_20030028194556 986499a5-f623-fe43-9aeb-9e7276a8be6c): describe transacces

NRO : Senantic Analysis Completed (retrial = false)

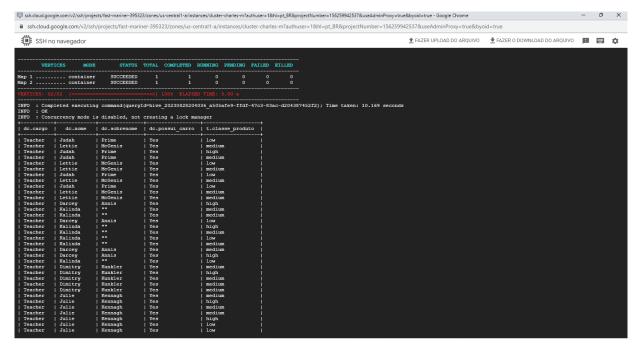
NRO : Returning Hive schema: Schema(fieldSchemass[FieldSchema(name:coll name; type:string, comment:from descrializer), FieldSchema (name:data_type, type:string, comment:from descrializer), FieldSchema (name:d
```

#### select \* from transacoes limit 100;



- 4. Formulação de perguntas analíticas a serem respondidas com os dados
- 5. Consultas SQL que respondem às perguntas elaboradas
- 1. Visualizar a classe dos produtos comprados de todos os clientes que compraram bicicletas com o cargo de 'Teacher' e que possuem carro.

select
dc.cargo,
dc.nome,
dc.sobrenome,
dc.possui\_carro,
t.classe\_produto
from demogra\_cliente as dc
JOIN transacoes as t
ON dc.customer\_id = t.customer\_id
where cargo = 'Teacher' and possui\_carro = 'Yes';



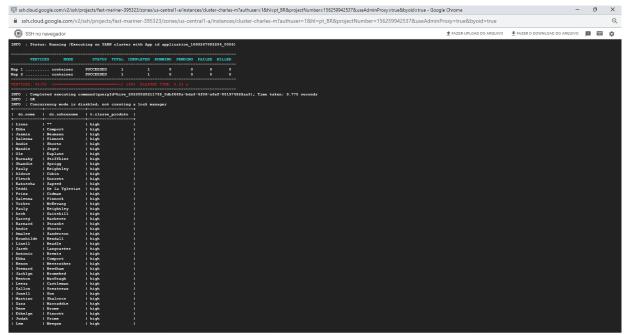
2. Visualizar a soma do valor de todos os produtos vendidos no mês de 'dezembro' do ano de '2017'.

select sum (preco\_lista)
from transacoes
where mes = 'dezembro';

```
No. 1 Complete variety and container with the container and the co
```

3. Selecionar nomes e sobrenomes de 50 clientes que compraram bicicletas da classe 'High'.

select
dc.nome,
dc.sobrenome,
t.classe\_produto
from demogra\_cliente as dc
JOIN transacoes as t
ON dc.customer\_id = t.customer\_id
where classe\_produto = 'high' limit 50;



4. Selecionar nomes das 50 clientes do sexo 'female' que compraram bicicletas da classe 'High'.

select

dc.nome,

dc.sobrenome,

dc.sexo,

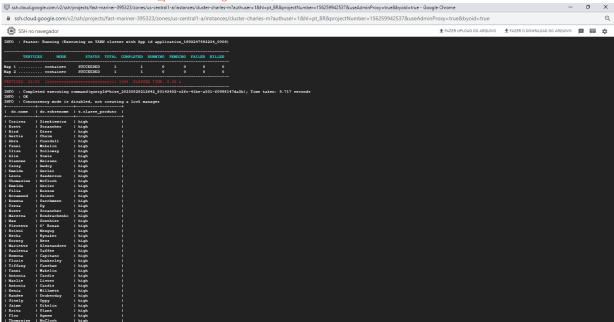
 $t.classe\_produto$ 

from demogra\_cliente as dc

JOIN transacoes as t

ON dc.customer\_id = t.customer\_id

where sexo = 'Female' and classe\_produto = 'High' limit 50;



5. Pegar todos os clientes masculino com cargo de TI que não possui carro e compraram bicicletas da classe 'low'.

select
dc.nome,
dc.categoria\_cargo,
t.classe\_produto,
dc.possui\_carro
from demogra\_cliente as dc
JOIN transacoes as t
ON dc.customer\_id = t.customer\_id
where categoria\_cargo = 'IT' and possui\_carro = 'No' and classe\_produto = 'low' and sexo= 'Male';

### 5. Proposta de evolução do trabalho

Exibir um gráfico com a evolução das vendas por ano ou mês. Criar um dashboard para melhor visualização das perguntas analíticas. Aumentar o número de clusters para eficiência das consultas.

# Link do trabalho com repositório no github:

https://github.com/Charles-Melo-TI/trabalho-hadoop

# Referências:

https://www.devmedia.com.br/hadoop-fundamentos-e-instalacao/29466 https://www.kaggle.com/datasets/rohitsahoo/bicycle-store-dataset